




2026年度 前期 データマイニング特論 (I20教室)
第14回 2026年7月16日(木) 13:10~14:40



データマイニング特論

第14回

公平性・倫理と再現性

本科目シラバスの確認 3（授業計画）

#	日程	内容
第1回	4/16（木）	ガイダンス、イントロダクション+Python環境構築
第2回	4/23（木）	pandasによるデータ操作の基礎
第3回	4/30（木）	探索的データ分析（EDA）と可視化（オンデマンド）
第4回	5/7（木）	データの前処理と特徴量エンジニアリング
第5回	5/14（木）	分類の基礎 — k近傍法と決定木
第6回	5/21（木）	アンサンブル学習
第7回	5/28（木）	線形分類モデルと回帰
第8回	6/4（木）	モデル評価・選択と不均衡データ
第9回	6/11（木）	クラスタリング手法
第10回	6/18（木）	アソシエーション分析と異常検知
第11回	6/25（木）	テキストマイニング
第12回	7/2（木）	時系列データマイニング
第13回	7/9（木）	深層学習の概観と使いどころ
第14回	7/16（木）	公平性・倫理と再現性
第15回	7/23（木）	まとめ

【Point】 やむなく欠席した場合、資料を確認のうえ不明ところは聞いてください。

1



バイアスはどこから来るか

データ・ラベル・代表性／実社会の失敗例

モデルは、すでに「決めて」いる

【機械学習は現実の意思決定に使われている。採用・与信・医療・再犯予測など、人の人生を左右する場面。】

公平か？

特定の集団に不利益が偏っていないか

守れているか？

誰かのプライバシーを暴いていないか

再現できるか？

他人と未来の自分が同じ結果を出せるか

精度が高くても、この3つを外すと「使ってはいけないモデル」になる。
今日はこの3点がポイント！

3つの発生源

① データの偏り

集める段階での偏り。

特定の地域・層が過小／過大に含まれる（サンプリングバイアス）。

② ラベルの偏り

過去の人間の判断を正解として学ぶと、過去の差別まで学習してしまう。

③ 代表性の欠如

学習データに存在しない集団には、そもそも当てはまらない・外れる。

共通点：どれも「見えない」。

精度指標には出てこないなので、意識して群別に見ないと気づけない。

有名な失敗例（分野を問わず）

再犯予測 COMPAS

偽陽性率が特定集団に偏ったと報道され論争に

採用AI

過去の履歴書で学習し、女性に不利な傾向が出て運用停止

顔認識

肌の色・性別で精度差（暗い肌の女性で誤りが多い）

音声認識

非母語話者や方言で認識精度が下がる

いずれも「精度は出ていた」。それでも使ってよいとは限らない。。。

2

公平性をどう測るか

群別に見る／3つの指標／不可能性



まず群ごとに分けて見る

【混同行列を、集団ごとに作ると、全体の正解率が高くても、群別に見ると景色が変わる。】

陽性予測率

各群で『陽性』と予測される割合。均等なら demographic parity。

真陽性率 TPR

本当に陽性の人を拾えた割合。群で均等なら 機会均等。

群別 正解率

全体では見えない、集団ごとの当たり外れ。

全体正解率という1つの数字は、群間の不均衡を覆い隠す。

代表的な3つの公平性指標

①人口統計学的パリティ

陽性と予測される割合を群間でそろえる。 (結果の均等)

② 機会均等

本当に陽性の人を拾う割合(TPR)を群間でそろえる。 (見逃しの均等)

③ 均等化オッズ

TPRとFPRの両方を群間でそろえる。 もっとも厳しい。 (誤りの均等)

どれを選ぶかで「公平」の意味が変わる。 唯一の正解はない。

3つは同時には満たせない

集団ごとに基準率（本当に陽性の割合）が違うと、**複数の公平性指標を同時に満たすことは数学的に不可能**だと証明されています（不可能性定理）。

だから「公平なモデル」は技術だけでは決まらない。
どの公平を優先するかという価値判断が必ず入る。

エンジニアの仕事は「公平にする」ことではなく、
「どの公平を選び、何を犠牲にしたか」を説明できることである。

本日の環境準備

いろいろ試してみよう！

```
# 日本語対応のモジュールをインストールする(その1)
!pip install japanize-matplotlib
# 日本語対応のモジュールをインストールする(その2)
!apt-get install -y fonts-ipafont-gothic
```

```
# 各ライブラリーをインポートする
import time, warnings
import numpy as np
import pandas as pd
import matplotlib
import matplotlib.pyplot as plt
try:
    import japanize_matplotlib # noqa
except Exception:
    pass
plt.rcParams["axes.unicode_minus"] = False
warnings.filterwarnings("ignore")

RNG = np.random.default_rng(20260716)
```

データの読み込み (1)

いろいろ試してみよう！

データ読み込み

```
LISTINGS_URL = ("https://data.insideairbnb.com/japan/kant%C5%8D/tokyo/"
                "2023-06-29/visualisations/listings.csv")
FEAT_NUM = ["latitude", "longitude", "minimum_nights", "number_of_reviews",
            "reviews_per_month", "availability_365", "calculated_host_listings_count"]
FEAT_CAT = ["neighbourhood", "room_type"]
def synthesize_listings(n=15000):
    wards = ["Shinjuku", "Shibuya", "Taito", "Sumida", "Toshima", "Nakano", "Setagaya", "Ota", "Katsushika", "Arakawa"]
    wp = dict(zip(wards, [1.0, 1.05, 0.85, 0.75, 0.7, 0.6, 0.55, 0.45, 0.35, 0.4]))
    w = np.array([2.2, 2.0, 1.6, 1.3, 1.1, 0.9, 0.9, 0.8, 0.7, 0.7]); w = w/w.sum()
    ward = RNG.choice(wards, n, p=w)
    rooms = ["Entire home/apt", "Private room", "Hotel room", "Shared room"]
    re_ = {"Entire home/apt": 1.0, "Private room": 0.45, "Hotel room": 0.7, "Shared room": 0.25}
    room = RNG.choice(rooms, n, p=[0.62, 0.30, 0.05, 0.03])
    mn = np.clip(RNG.lognormal(0.7, 0.8, n).astype(int), 1, 365)
    nrev = RNG.poisson(np.clip(RNG.lognormal(2.2, 1.1, n), 0, None)).astype(int)
    rpm = np.round(np.clip(RNG.gamma(1.5, 0.7, n), 0, None), 2)
    av = np.clip((RNG.beta(1.4, 1.6, n)*365).astype(int), 0, 365)
    hl = np.clip(RNG.lognormal(0.6, 1.0, n).astype(int), 1, None)
    lat = 35.68 + RNG.normal(0, 0.045, n); lon = 139.75 + RNG.normal(0, 0.055, n)
    wpar = np.array([wp[x] for x in ward]); ent = (room=="Entire home/apt"); shr = (room=="Shared room")
    price = (3600*np.array([re_[r] for r in room])*(0.6+0.8*wpar)
             *(1+0.9*ent*(wpar>0.8))
             *(0.75+0.5*np.exp(-((av-180)**2)/(2*70**2)))
             *np.where(mn<=3, 1.15, np.where(mn>=30, 0.8, 1.0))
             *(1+0.5*(nrev>20)*ent-0.3*(nrev>20)*shr)
             *(1+RNG.normal(0, 0.25, n)))
```

#次に続く。。

データの読み込み (2)

いろいろ試してみよう！

```
price = np.clip(price,1500,None).astype(int)
return pd.DataFrame({"neighbourhood":ward,"room_type":room,"latitude":lat.round(5),
    "longitude":lon.round(5),"minimum_nights":mn,"number_of_reviews":nrev,
    "reviews_per_month":rpm,"availability_365":av,
    "calculated_host_listings_count":hl,"price":price})

def load_listings():
    try:
        df = pd.read_csv(LISTINGS_URL)
        df["price"] = (df["price"].astype(str).str.replace(r"¥$,","",regex=True)
            .replace("",np.nan).astype(float))
        df = df[FEAT_NUM+FEAT_CAT+["price"]].dropna(subset=["price","room_type","neighbourhood"])
        df["reviews_per_month"] = df["reviews_per_month"].fillna(0)
        df = df[(df["price"]>0)&(df["price"]<df["price"].quantile(0.99))]
        print(f"[実データ] listings 読み込み: {len(df):,} 件")
        return df.reset_index(drop=True), True
    except Exception as e:
        print(f"[フォールバック] 実データ取得不可({type(e).__name__})。合成データで続行。")
        return synthesize_listings(), False
```

#次に続く。。。

データの読み込み (3)

いろいろ試してみよう！

```
df, IS_REAL = load_listings()
thr = int(df["price"].median())
y = (df["price"] >= thr).astype(int).values
X = df[FEAT_NUM+FEAT_CAT].copy()
print(f"目的変数=高価格帯か(中央値 {thr}) 正例率 {y.mean():.3f} 件数 {len(df):,}")
```

```
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import OrdinalEncoder
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.ensemble import HistGradientBoostingClassifier
from sklearn.metrics import accuracy_score
```

```
pre = ColumnTransformer([("cat", OrdinalEncoder(handle_unknown="use_encoded_value",
                                                unknown_value=-1), FEAT_CAT)], remainder="passthrough")
```

```
def make_gbd():
    return Pipeline([("pre", pre), ("clf", HistGradientBoostingClassifier(
        categorical_features=[0,1], random_state=0))])
```

```
Xtr, Xte, ytr, yte = train_test_split(X, y, test_size=0.25, random_state=0, stratify=y)
gb = make_gbd(); gb.fit(Xtr, ytr)
proba = gb.predict_proba(Xte)[:,-1]
pred = (proba >= 0.5).astype(int)
print(f"[分類器] 全体正解率 {accuracy_score(yte, pred):.3f}")
```

[実データ] listings 読み込み: 11,055 件
目的変数=高価格帯か (中央値 14286) 正例率 0.502 件数 11,055
[分類器] 全体正解率 0.783

公平性ギャップ (1)

いろいろ試してみよう！

```
print("\n=== ① 公平性ギャップ(room_type群別) ===")
g = Xte["room_type"].values
groups = ["Entire home/apt", "Private room", "Hotel room", "Shared room"]
rows=[]
for grp in groups:
    m = (g==grp)
    if m.sum()==0: continue
    ppr = pred[m].mean() # 陽性予測率(demographic parity)
    tpr = pred[m][yte[m]==1].mean() if (yte[m]==1).sum()>0 else np.nan # 機会均等
    acc = accuracy_score(yte[m], pred[m])
    rows.append((grp, m.sum(), ppr, tpr, acc))
    print(f" {grp:16s} n={m.sum():5d} 陽性予測率={ppr:.3f} TPR={tpr:.3f} 正解率={acc:.3f}")
pdp = np.nanmax([r[2] for r in rows]) - np.nanmin([r[2] for r in rows])
eop = np.nanmax([r[3] for r in rows]) - np.nanmin([r[3] for r in rows])
print(f" → 陽性予測率の群間差(demographic parity gap) = {pdp:.3f}")
print(f" → TPRの群間差(equal opportunity gap) = {eop:.3f}")
```

しきい値を動かすとギャップが変わる

```
print(" しきい値別 陽性予測率ギャップ:")
thr_list=[0.3,0.4,0.5,0.6,0.7]; gap_by_t=[]
for t in thr_list:
    pr = (proba>=t).astype(int)
    pprs=[pr[g==grp].mean() for grp in groups if (g==grp).sum()>0]
    gp=max(pprs)-min(pprs); gap_by_t.append(gp)
    print(f" t={t:.1f}: gap={gp:.3f}")
```

#次に続く。。。

公平性ギャップ (2)

いろいろ試してみよう！

```
# 図①
fig, (a1,a2)=plt.subplots(1,2,figsize=(11,4),gridspec_kw={"width_ratios":[1.25,1]})
labels=[r[0].replace("Entire home/apt","Entire\nhome") .replace("Private room","Private\nroom")
        .replace("Hotel room","Hotel\nroom").replace("Shared room","Shared\nroom") for r in rows]
xx=np.arange(len(rows)); wd=0.38
a1.bar(xx-wd/2,[r[2] for r in rows],wd,label="陽性予測率",color="#3B4CC0",edgecolor="white")
a1.bar(xx+wd/2,[r[3] for r in rows],wd,label="TPR(機会均等)",color="#E8833A",edgecolor="white")
a1.set_xticks(xx); a1.set_xticklabels(labels,fontsize=9); a1.set_ylim(0,1)
a1.set_title("群ごとに予測が偏る(room_type=保護属性の代理)"); a1.legend(fontsize=9)
a1.grid(axis="y",alpha=.3); a1.set_axisbelow(True)
a2.plot(thr_list,gap_by_t,"o-",color="#C0392B",lw=2)
a2.set_xlabel("判定しきい値"); a2.set_ylabel("陽性予測率の群間差")
a2.set_title("しきい値しだいで「公平」は変わる"); a2.grid(alpha=.3); a2.set_axisbelow(True)
plt.tight_layout(); plt.show()
```


公平性ギャップ (3)

=== ① 公平性ギャップ (room_type群別) ===

Entire home/apt	n= 2038	陽性予測率=0.612	TPR=0.855	正解率=0.771
Private room	n= 594	陽性予測率=0.379	TPR=0.714	正解率=0.803
Hotel room	n= 69	陽性予測率=0.522	TPR=0.848	正解率=0.812
Shared room	n= 63	陽性予測率=0.000	TPR=0.000	正解率=0.937

→ 陽性予測率の群間差(demographic parity gap) = 0.612

→ TPRの群間差(equal opportunity gap) = 0.855

しきい値別 陽性予測率ギャップ:

t=0.3: gap=0.806


t=0.4: gap=0.722

t=0.5: gap=0.612


t=0.6: gap=0.485

t=0.7: gap=0.362

群ごとに予測が偏る (room_type=保護属性の代理)



しきい値しだいで「公平」は変わる



3



プライバシー

匿名化の限界／再識別／差分プライバシー

「名前を消せば匿名」ではない

【氏名やIDを消しても、いくつかの属性の『組み合わせ』で個人は特定できる。
これを準識別子と呼ぶ。】

① k-匿名性

同じ属性の組み合わせを持つ人が最低k人いる状態。
k=1なら一意＝特定可能。

② 準識別子

単体では特定できないが、組み合わせると効く属性
(地域・年齢・稼働状況など)。

再識別は実際に起きている

① Netflix Prize

匿名の映画評価データが、外部サイトの公開評価と突き合わせて個人を特定された。

② 位置情報

運動アプリの公開ヒートマップから、非公開だった施設の位置が露呈。通勤パターンから自宅も割れる。

③ 匿名データ一般

生年月日・郵便番号・性別の3つだけで、多くの人が一意に特定できるとされる。

「匿名化した」は安全の保証ではない。
何と突き合わされ得るか、を常に考える必要がある。

準識別子による再識別（Ⅰ）

いろいろ試してみよう！

```
print("\n=== ② 準識別子による再識別(k-匿名性) ===")
d = df.copy()
d["lat2"]=d["latitude"].round(2); d["lon2"]=d["longitude"].round(2)
d["av_bin"]=(d["availability_365"]//30)
qi_sets=[
    ("neighbourhood", "地域のみ"),
    ("neighbourhood","room_type", "+部屋タイプ"),
    ("neighbourhood","room_type","av_bin", "+稼働月数"),
    ("neighbourhood","room_type","av_bin","lat2","lon2", "+緯度経度(小数2桁)"),
    ("neighbourhood","room_type","av_bin","lat2","lon2","calculated_host_listings_count", "+掲載件数"),
]
uniq_frac=[]; labels2=[]
for qi,name in qi_sets:
    grp_sizes = d.groupby(qi).size()
    key = d.groupby(qi).ngroup().map(grp_sizes.reset_index(drop=True))
    sizes = d.groupby(qi)[qi[0]].transform("size")
    uf = (sizes==1).mean()
    uniq_frac.append(uf); labels2.append(name)
    print(f" {name:22s} 準識別子{len(qi)}個 → 一意(k=1)な割合 {uf*100:5.1f}% ({int((sizes==1).sum())}件)")
```

#次に続く。。。

準識別子による再識別（2）

いろいろ試してみよう！


```
fig, ax=plt.subplots(figsize=(9,4.3))
bars=ax.bar(range(len(uniq_frac)),[u*100 for u in uniq_frac],color="#2C7A7B",edgecolor="white")
for i,u in enumerate(uniq_frac):
    ax.text(i,u*100+1,f"{u*100:.1f}%",ha="center",va="bottom",fontsize=9)
ax.set_xticks(range(len(labels2))); ax.set_xticklabels(labels2,fontsize=9,rotation=12,ha="right")
ax.set_ylabel("一意に特定できる割合 (%)"); ax.set_ylim(0,105)
ax.set_title("準識別子を足すほど「匿名」は崩れる")
ax.grid(axis="y",alpha=.3); ax.set_axisbelow(True)
plt.tight_layout(); plt.show()
```

準識別子による再識別（3）

=== ② 準識別子による再識別（k-匿名性） ===

地域のみ	準識別子1個 → 一意(k=1)な割合	0.0%	(0件)
+部屋タイプ	準識別子2個 → 一意(k=1)な割合	0.1%	(9件)
+稼働月数	準識別子3個 → 一意(k=1)な割合	1.7%	(190件)
+緯度経度(小数2桁)	準識別子5個 → 一意(k=1)な割合	14.8%	(1635件)
+掲載件数	準識別子6個 → 一意(k=1)な割合	32.7%	(3614件)

準識別子を足すほど「匿名」は崩れる



差分プライバシー：ノイズで守る

【集計結果にわざとノイズを足し、『特定の1人が含まれるか否か』で答えがほとんど変わらないようにする。】

プライバシー予算 ϵ

小さい ϵ → ノイズ大 → 強い保護・低い精度
大きい ϵ → ノイズ小 → 弱い保護・高い精度

実運用の例

米国情勢調査2020が全面採用。
スマホの利用統計収集などでも
使われる、現代の標準的な手法。

完全な匿名化は難しい。
だから『どれだけ守るか』を ϵ という数字で管理する、という発想。

差分プライバシー (I)

いろいろ試してみよう！

```
print("\n=== ③ 差分プライバシー(区ごとの件数クエリにLaplaceノイズ) ===")
counts = df["neighbourhood"].value_counts().sort_values(ascending=False).head(10)
sens=1.0 # count query の感度
eps_list=[0.1,0.5,1.0,2.0,5.0]
mae=[]
for eps in eps_list:
    scale=sens/eps
    errs=[]
    for _ in range(200):
        noisy=counts.values + RNG.laplace(0,scale,size=len(counts))
        errs.append(np.mean(np.abs(noisy-counts.values)))
    mae.append(np.mean(errs))
    print(f"  $\epsilon$ ={eps:.1f}: 平均絶対誤差 {np.mean(errs):6.1f} 件(scale={scale:.1f})")
```

#次に続く。。。

差分プライバシー (2)

いろいろ試してみよう！

図③: 左=真値 vs ノイズ(ϵ 小/大)、右=誤差 vs ϵ



```
fig, (a1, a2) = plt.subplots(1, 2, figsize=(11, 4), gridspec_kw={"width_ratios": [1.35, 1]})
xw = np.arange(len(counts)); ww = 0.27
noisy_lo = counts.values + RNG.laplace(0, sens/0.1, size=len(counts))
noisy_hi = counts.values + RNG.laplace(0, sens/5.0, size=len(counts))
a1.bar(xw - ww, counts.values, ww, label="真の件数", color="#334155", edgecolor="white")
a1.bar(xw, np.maximum(noisy_lo, 0), ww, label="ε=0.1(強い保護)", color="#C0392B", edgecolor="white")
a1.bar(xw + ww, np.maximum(noisy_hi, 0), ww, label="ε=5.0(弱い保護)", color="#E8833A", edgecolor="white")
a1.set_xticks(xw); a1.set_xticklabels([c[:6] for c in counts.index], rotation=30, ha="right", fontsize=8)
a1.set_ylabel("件数"); a1.set_title("ノイズで真値を隠す(区ごとの件数)"); a1.legend(fontsize=8)
a1.grid(axis="y", alpha=.3); a1.set_axisbelow(True)
a2.plot(eps_list, mae, "o-", color="#6B21A8", lw=2)
a2.set_xlabel("プライバシー予算 ε(小=強い保護)"); a2.set_ylabel("平均絶対誤差(件)")
a2.set_title("ε対効用のトレードオフ"); a2.grid(alpha=.3); a2.set_axisbelow(True)
plt.tight_layout(); plt.show()
```

差分プライバシー (3)

=== ③ 差分プライバシー (区ごとの件数クエリにLaplaceノイズ) ===

$\epsilon=0.1$: 平均絶対誤差 9.9 件 (scale=10.0)
 $\epsilon=0.5$: 平均絶対誤差 2.0 件 (scale=2.0)
 $\epsilon=1.0$: 平均絶対誤差 1.0 件 (scale=1.0)
 $\epsilon=2.0$: 平均絶対誤差 0.5 件 (scale=0.5)
 $\epsilon=5.0$: 平均絶対誤差 0.2 件 (scale=0.2)

ノイズで真値を隠す (区ごとの件数)

 ϵ 対効用のトレードオフ

4

再現性

再現の危機／壊す要因／良い実践



「もう一度やったら違う結果」問題

① 心理学の再現性の危機

有名研究を追試したら、多くが再現できなかった、という大規模検証が話題に。

② 経済政策の論文

集計処理のミス（表計算ソフトの範囲指定誤り）で結論が覆り、政策論争にまで発展。

③ 機械学習の論文

コード・データ・乱数種が公開されず、他者が結果を再現できないことが多い。

再現できない結果は、正しくても『検証できない』。
科学でも実務でも通用しない。

何が再現を壊すのか

乱数種(seed)

分割・初期化がランダムだと毎回変わる

データのバージョン

いつ取得したデータか。更新で結果が動く

ライブラリのversion

同じコードでも版が違えば挙動が変わる

記録されない前処理

手で直した加工は再現できない

セルの実行順

上から順でないとはれる

環境依存

OS・GPU差で微妙にずれることも

再現できる分析にするために

seedを固定する

乱数を使う所は種を明示

環境を固定・記録

ライブラリ版を requirements 等に残す

データにバージョン

取得日・出典を記録して保存

上から順に通す

Notebookは全実行して壊れないか確認

特別なことではなく、少しの規律で、未来の自分と他人が同じ結果に辿り着ける。

```
print("\n=== ④ 再現性(seed無し20回 vs seed固定) ===")
accs_noseed=[]
for i in range(20):
    Xa,Xb,ya,yb = train_test_split(X,y,test_size=0.25,stratify=y) # random_stateなし
    mm=make_gbdtd(); mm.fit(Xa,ya)
    accs_noseed.append(accuracy_score(yb, mm.predict(Xb)))
accs_noseed=np.array(accs_noseed)
# seed固定
Xa,Xb,ya,yb=train_test_split(X,y,test_size=0.25,stratify=y,random_state=0)
mm=make_gbdtd(); mm.fit(Xa,ya); acc_seed=accuracy_score(yb,mm.predict(Xb))
print(f"  seed無し20回: 正解率 {accs_noseed.min():.3f}~{accs_noseed.max():.3f}   幅={accs_noseed.max()-
accs_noseed.min():.3f}")
print(f"  seed固定      : 正解率 {acc_seed:.3f}(毎回同じ)")

fig,ax=plt.subplots(figsize=(9,4.3))
ax.hist(accs_noseed,bins=10,color="#94A3B8",edgecolor="white",label="seed無し(20回)")
ax.axvline(acc_seed,color="#C0392B",lw=2.5,ls="--",label=f"seed固定={acc_seed:.3f}")
ax.set_xlabel("テスト正解率"); ax.set_ylabel("回数")
ax.set_title("seedを外すと結果がぶれる=再現できない")
ax.legend(); ax.grid(axis="y",alpha=.3); ax.set_axisbelow(True)
plt.tight_layout(); plt.show()
```



再現性 (2)

=== ④ 再現性 (seed無し20回 vs seed固定) ===

seed無し20回: 正解率 0.755~0.784 幅=0.028

seed固定 : 正解率 0.783 (毎回同じ)

seedを外すと結果がぶれる=再現できない



The background is a gradient from dark purple at the top to dark blue at the bottom, speckled with small white dots. On the left side, there are several concentric circular patterns. A large circle has a degree scale from 140 to 260. Other smaller circles and arcs are scattered around, some with arrows indicating direction.

まとめ

出す前に、3つを自問する

① 公平

群ごとに見たか。誰かに不利益が偏っていないか。

② プライバシー

誰かを特定・暴露しないか。匿名化を過信していないか。

③ 再現

他人と未来の自分が、同じ結果を再現できるか。

「技術的に正しい」と「使ってよい」は別。

5

本日の課題

頑張ってください。



課題

【課題】 期限：2026/7/22（水） 23：59まで

WebClassの『データマイニング特論』アクセスし、
本日の日付が記載される「課題」を期限内に実施してください。

・ WebClass -> データマイニング特論 -> 【第14回（7/16）】課題

（課題1） 本日の演習で「いろいろ試してみよう！」の中で実施した入出力コードを
html形式でエクスポートし、提出しなさい。

html形式にする手順

- ①ipynb形式でダウンロード（ファイル名の例：aaa.ipynb）
- ②再び「ファイル」へアップロード
- ③以下のコマンドを入力
!jupyter nbconvert --to html "aaa.ipynb"

【ADSセミナー】

本学の「先端データ科学研究センター」が主催するセミナーが6/25（木）から4週にわたって開催されます。

内容が盛りだくさんなので、**研究室を選択する前の参考になる**かと思います。

事前登録フォームから申し込みあり。

【Point】 普段の授業では聞けない話もあるかも！？

ADSセミナー

対象 東京情報大学
全学部・学年/大学院生/教職員

会場 1号館 201教室

【第1回】 6/25（木） 16:30 - 18:00

講師： 釣井 達也 先生
総合情報学科 准教授（数理情報研究ユニット）



量子ウォークに潜む群構造について

量子ウォークはランダムウォークの量子版と解釈される数学モデルであり、その振る舞いはランダムウォークと大きく異なります。本セミナーでは、量子ウォークの簡単な具体例を通してランダムウォークとの違いを観察します。特に、量子ウォークに潜む群構造に着目し、この群構造を活用して、量子ウォークの特徴的な挙動のひとつである「周期」を求める方法について紹介します。

【第2回】 7/2（木） 16:30 - 18:00

講師： 早稲田 篤志 先生
総合情報学科 准教授（情報セキュリティ研究ユニット）



個人情報保護と機械学習

プライバシーに関する情報は解析して使用することで有益な情報を得られることが期待できます。一方、漏洩等で外部に漏れると大きな問題となることがあります。そこで、基本的なプライバシー保護の指標を紹介し、機械学習との関係を考察します。

【第3回】 7/9（木） 16:30 - 18:00

講師： 西村 明 先生
総合情報学科 教授（情報メディア学系）



音響法科学（オーディオ・フォレンジクス）

音響法科学は、音響学の原理と技術を、犯罪捜査・法廷および不正等の検知のために活かす研究と学問を指します。話者識別、雑音除去と音声強調、録音属性推定に大別され、本講演では、前二者を概観したのち、AI音声の判別を含む後者の研究について概説します。

【第4回】 7/16（木） 16:30 - 18:00

講師： 小早川 睦貴 先生
総合情報学科 准教授（生命情報研究ユニット）



身体情報から読みとる心の働き

心理学的研究で心を読み取る際には、さまざまな人間の「反応」を測ることが不可欠です。一般的には反応時間や正答率、表情など目に見える反応を使いますが、発汗や視線など、目に見えない反応などを使って心を読む心理学的研究を紹介します。

<参加登録>

右のQRコードを読み取り、参加登録フォームへアクセスの上、必要事項を記入してお申し込みください。



受付期間： 5/26（火）～ 7/16（木）

<https://forms.office.com/r/JRmJe3qNmh>

早期研究体験プロジェクト

（対象：学部1・2年次）

本プログラムに興味のある学生は、先端データ科学研究センターまでお問い合わせください。

随時
募集中

<お問い合わせ>

東京情報大学 総合情報学部
先端データ科学研究センター
ads@rsch.tuis.ac.jp

