



機械学習特論（第8回）

ニューラルネットワーク



ニューラルネットワークの歴史（1）


- 1943：マッカロ（W.S. McCulloch）とピッツ（W. Pitts）が神経回路をモデル化
 - 脳の神経回路（ニューラルネットワーク）を数理モデルによってモデル化，並列処理
 - ただし，例題に応じて自発的にモデルの重みを更新する，いわゆる学習ではない
- 1949：ヘブ（D.O. Hebb）が，神経細胞の学習法則を提案
 - ヘブの学習法則は，「使われる結合は強化されるという」生体の特徴を取り入れた
 - しかし，ヘブの学習法則は，現実の問題を解決するほどの学習能力はなかった．
- 1958：ローゼンブラット（Rosenblatt）が，パーセプトロンを提案
 - 現実の問題を解くことができる初めてのモデル，神経回路モデルに対する期待が高まる
- 1969：ミンスキー（Minsky）とパパート（Papert）がパーセプトロンの限界を証明
 - パーセプトロンは，線形分離可能と呼ばれる単純な問題しか解けないことを数学的に証明
 - ニューラルネットワーク研究は，再び，冬の時代へ

ニューラルネットワークの歴史 (2)

- 1986 : ラメルハート, ヒントン, ウィリアムズ (Rumelhart, Hinton, Williams) による階層型ネットワークモデルの提案
 - 学習に逆伝播学習と呼ばれる方法を採用, 通常は入力層, 隠れ層, 出力層の3層構造
 - 原理が単純で効果が高かったため, 産業界でも適用される. ニューロブームの到来
 - 短所: 過学習 (学習データを予測できるが, 未知のデータを予測できない) の問題. 過学習の問題が起きない手法が注目 (SVM) され, 再び, 研究が下火になる
- 2006 : 層をより多層にした深層学習 (Deep Learning) の一種である深層信念ネットワークをヒントン (Geoffrey Hinton) が提案
- 2012 : 世界的な画像認識コンテストILSVRCで, 深層学習の手法を用いた手法Supervisionが圧勝し, 深層学習が注目を集める
- 2014 : Apple社はSiriの音声認識を深層学習の手法を用いたシステムに変更
- 2016 : Googleの開発した深層学習手法を用いたAI「アルファ碁」が世界トップ級の棋士と勝負し, 勝利する
- 2016 : AUDIやBMW社で, 自動車の自動運転に深層学習の手法が利用される

シグモイド関数

$$\sigma(x) = \frac{1}{1 + e^{-x}} = \frac{1}{1 + \exp(-x)} = \frac{e^x}{1 + e^x}$$



- シグモイド関数は $(-\infty, \infty)$ の入力値を $[0, 1]$ の出力値に変換する関数
- 記号 σ を用いているが標準偏差ではないことに注意

シグモイド関数の導関数

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

$$\begin{aligned}\sigma'(x) &= -\frac{(1 + e^{-x})'}{(1 + e^{-x})^2} = \frac{e^{-x}}{(1 + e^{-x})^2} \\ &= \frac{1 + e^{-x} - 1}{(1 + e^{-x})^2} = \frac{1}{1 + e^{-x}} - \frac{1}{(1 + e^{-x})^2} \\ &= \sigma(x) - \sigma(x)^2 \\ &= \sigma(x)(1 - \sigma(x))\end{aligned}$$

分数関数の微分公式

$$\left(\frac{1}{f(x)}\right)' = -\frac{f'(x)}{f(x)^2}$$

シグモイド関数の導関数は、シグモイド関数の値 $\sigma(x)$ を使って計算できることに注意

アヤメ (iris) データ

- 統計学の巨匠, Fisherが1936年に発表した判別分析の論文で利用されたデータ. 収集したのは植物学者のAnderson
- 3 種のアヤメ
 - Setosa (ヒオウギアヤメ)
 - Versicolor
 - Virginica
- がく片 (Sepal) の長さ と 幅, 花びら (Petal) の長さ と 幅の 4 変数 (連続した値をとる量的変数)
- アヤメの種類 (質的変数) をその他の変数にもとづいて予測する判別問題の典型的な例題データ



教師付き学習における予測モデル ～アヤメの種類の予測～

入力変数： x

x_1 ：がく片の長さ

x_2 ：がく片の幅

x_3 ：花びらの長さ

x_4 ：花びらの幅



出力変数： y
アヤメの種類


教師変数： t
正しいアヤメの種類

予測モデルは、入力変数 x に対して、出力変数 y を返す関数 $f(x)$ とみなすことができる。

$$y = f(x)$$

機械学習のアルゴリズムは、教師変数 t の情報を利用しながら、出力変数 y が出来るだけ正解となる様に予測モデル $f(x)$ を構成する

階層型ネットワークモデル（3層型）



層の数：3

入力層の素子数（バイアス素子含む）： $D+1$

中間層の素子数（バイアス素子含む）： $M+1$

出力層の素子数： K

M は、実行前に設定

例：アヤメの種類の予測

$D=4$


（がく片と花びらの長さ・幅）

$K=3$

（アヤメの種類）

入力層・中間層のうち緑色の素子は、常に1が入力されるバイアス素子

重みの表記




$w_{ji}^{(1)}$:
入力層の*i*番目の素子と
中間層の*j*番目の素子をつな
ぐ重み

$w_{j0}^{(1)}$:
中間層の*j*番目の素子へつな
ぐバイアスパラメータ

$w_{kj}^{(2)}$:
中間層の*j*番目の素子と
出力層の*k*番目の素子をつ
なぐ重み

$w_{k0}^{(2)}$:
出力層の*k*番目の素子へつ
なぐバイアスパラメータ


多入力多出力関数としての ニューラルネットワーク



ニューラルネットワークは
 D 変数を入力とする K 個の
関数を意味する

$$\begin{aligned} y_K &= f_K(x_1, x_2, \dots, x_D) \\ y_{K-1} &= f_{K-1}(x_1, x_2, \dots, x_D) \\ &\vdots \\ y_2 &= f_2(x_1, x_2, \dots, x_D) \\ y_1 &= f_1(x_1, x_2, \dots, x_D) \end{aligned}$$

教師変数が連続値の場合の評価関数 (予測値の当てはまり具合を評価する関数)



出力変数 y_k と教師変数 t_k の差を評価

教師変数が連続値の場合の
代表的な評価関数

最小二乗誤差


$$E(x_{11}, x_{12}, \dots, x_{nd}, \dots, x_{ND}) \\ = \frac{1}{2} \sum_{n=1}^N \sum_{k=1}^K (y_{nk} - t_{nk})^2$$

x_{nd} : n 番目のサンプルに対する d 番目の
入力値

y_{nk} : n 番目のサンプルに対する y_k の値

t_{nk} : n 番目のサンプルに対する t_k の値

教師変数が離散値の場合の評価関数



教師変数に1-of-K符号化を行う
アヤメの種類予測ならば
 $K=3$ であり、
例えば、
Setosaならば

$$(t_1 = 1, t_2 = 0, t_3 = 0)$$

Versicolorならば

$$(t_1 = 0, t_2 = 1, t_3 = 0)$$


Verginicaならば

$$(t_1 = 0, t_2 = 0, t_3 = 1)$$

教師変数が離散値の場合の代表的評価関数
交差エントロピー誤差

$$E(x_{11}, x_{12}, \dots, x_{nd}, \dots, x_{ND}) \\ = - \sum_{n=1}^N \sum_{k=1}^K \{ t_{nk} \ln(y_{nk}) + (1 - t_{nk}) \ln(1 - y_{nk}) \}$$

順伝搬と逆伝搬




順伝搬：入力層から出力層へ向かった計算

逆伝搬：出力層から入力層へ向かった計算。この時に重みが更新される

誤差逆伝播法：順伝搬と逆伝搬を繰り返しながら、評価関数が減少するように重みを更新するアルゴリズム→最急降下法

順伝搬：入力層から中間層への計算



入力層から中間層への計算
中間層の j 番目の素子への入力

$$a_j = \sum_{i=1}^D w_{ji}^{(1)} x_i + w_{j0}^{(1)} \\ j = 1, 2, \dots, M$$

例えば、中間層の 1 番目の素子の入力値は、

$$a_1 = w_{11}^{(1)} x_1 + w_{12}^{(1)} x_2 + \dots + w_{1D}^{(1)} x_D + w_{10}^{(1)}$$


入力層の 0 番目の素子は常に 1 が入力される素子と考えることができる

順伝搬：中間層の素子で行う計算

入力値をシグモイド関数： $(-\infty, \infty)$ の値を $[0, 1]$ の値に変換する関数

$$\sigma(x) = \frac{1}{1 + e^{-x}} = \frac{1}{1 + \exp(-x)} = \frac{e^x}{1 + e^x}$$

によって変換




中間層の入力値 a_j
の変換結果

$$z_j = \sigma(a_j)$$

を出力

順伝搬：中間層から出力層への計算



中間層から出力層への計算
中間層の k 番目の素子の入力

$$a_k = \sum_{j=1}^M w_{kj}^{(2)} z_j + w_{k0}^{(2)}$$
$$k = 1, 2, \dots, K$$

例えば、出力層の1番目の素子の入力値は、

$$a_1 = w_{11}^{(2)} z_1 + w_{12}^{(2)} z_2 + \dots + w_{1M}^{(2)} z_M + w_{10}^{(2)}$$

出力層の0番目の素子は
常に1が入力される素子
と考えることができる

順伝搬：出力層の素子で行う計算

教師変数が連続値の場合は、出力層では、変換を行わない
教師変数が離散値の場合は、出力層で、SoftMax関数による変換を行う

Softmax関数：シグモイド関数を多クラスへ拡張した関数

$$y_k = \frac{\exp(a_k)}{\sum_{j=1}^K \exp(a_j)}, k = 1, 2, \dots, K$$

式からもわかる様に $\sum_{k=1}^K y_k = 1$, $y(a_k) > 0$ であり, $y_k, k = 1, \dots, K$ を確率とみることができる.

先のアヤメの予測の例の場合、出力層の1番目の素子($k=1$)がSetosaに対応するならば, y_1 は, そのサンプルがSetosaである確率を表す。
2番目($k=2$), 3番目($k=3$)の素子も同様に該当するアヤメの種類の確率を表す。

学習：評価関数値の最小化

予測値 y_{nk} は, 重みの設定値によって決まるので, 評価関数は, 全ての重み $w_{10}^{(1)}, \dots, w_{D1}^{(1)}, \dots, w_{DM}^{(1)}, w_{01}^{(2)}, \dots, w_{MK}^{(2)}$ の関数と見ることが出来る.

評価関数が最小となる様に, 重み $w_{01}^{(1)}, \dots, w_{D1}^{(1)}, \dots, w_{DM}^{(1)}, w_{01}^{(2)}, \dots, w_{MK}^{(2)}$ を決定する.

目標値が連続値の場合の
代表的な評価関数

最小二乗誤差

$$E(w_{10}^{(1)}, \dots, w_{D1}^{(1)}, \dots, w_{DM}^{(1)}, w_{01}^{(2)}, \dots, w_{MK}^{(2)}) \\ = \frac{1}{2} \sum_{n=1}^N \sum_{k=1}^K (y_{nk} - t_{nk})^2$$

目標値が離散値の場合の代表的評価関数

交差エントロピー誤差

$$E(w_{10}^{(1)}, \dots, w_{D1}^{(1)}, \dots, w_{DM}^{(1)}, w_{01}^{(2)}, \dots, w_{MK}^{(2)}) \\ = - \sum_{n=1}^N \sum_{k=1}^K \{t_{nk} \ln(y_{nk}) + (1 - t_{nk}) \ln(1 - y_{nk})\}$$

バッチ学習とオンライン学習

全サンプルを
バッチに分割

1 番バッチ

$b = 1$

N_b サンプル

2 番バッチ

$b = 2$

N_b サンプル

⋮

B 番バッチ

$b = B$

N_b サンプル

- n 個のサンプルに対する評価関数に対して重み $w_{10}^{(1)}, \dots, w_{D1}^{(1)}, \dots, w_{DM}^{(1)}, w_{01}^{(2)}, \dots, w_{MK}^{(2)}$ の更新を塊 (バッチ) 毎に行う学習をバッチ学習と呼ぶ

b 番目のバッチに対する評価関数

$$E_b = E(w_{10}^{(1)}, \dots, w_{D1}^{(1)}, \dots, w_{DM}^{(1)}, w_{01}^{(2)}, \dots, w_{MK}^{(2)}) \\ = \frac{1}{2} \sum_{n=1}^{N_b} \sum_{k=1}^K (y_{nk} - t_{nk})^2$$

全サンプルに対する評価関数

$$E = E(w_{10}^{(1)}, \dots, w_{D1}^{(1)}, \dots, w_{DM}^{(1)}, w_{01}^{(2)}, \dots, w_{MK}^{(2)}) \\ = \frac{1}{2} \sum_{b=1}^B E_b$$

- N_b はバッチサイズ (1 つのバッチに含まれるサンプル数)、 B はバッチの数を表す。
- $N_b = 1$ 、すなわち、1 サンプル毎に重み $w_{10}^{(1)}, \dots, w_{D1}^{(1)}, \dots, w_{DM}^{(1)}, w_{01}^{(2)}, \dots, w_{MK}^{(2)}$ の更新を行う学習をオンライン学習と呼ぶ。 n 番目のサンプルに対する評価関数を

$$E_n = \frac{1}{2} \sum_{k=1}^K (y_{nk} - t_{nk})^2 \text{ と表す。}$$

逆伝搬

- 順伝搬では、与えられた重みのもとで、入力層→中間層→出力層と計算し、現在の重みのもとでの予測を行った。
- 逆伝搬では、評価関数の値が減少するように、重みの更新を行う。重みの更新は、出力層→中間層→入力層と順伝搬の逆方向に行う。
- 逆伝搬は、最急降下法と呼ばれる評価関数が減少する方向へ重みを移動させながら、最も評価関数が最小化される重みを探索する方法が、基本的な方法である。

復習：最急降下法（2変数の場合）

1. 閾値 $\varepsilon > 0$, ステップ幅 $\alpha > 0$ を設定する
2. x, y の初期値 x_0, y_0 を設定する
3. $\frac{\partial f}{\partial x}(x_t, y_t), \frac{\partial f}{\partial y}(x_t, y_t)$ の値を計算する
4. x の値を更新する. (x_t, y_t) は (x, y) の t 回目の更新値

$$x_{t+1} = x_t - \alpha \frac{\partial f}{\partial x}(x_t, y_t)$$
$$y_{t+1} = y_t - \alpha \frac{\partial f}{\partial y}(x_t, y_t)$$

5. 終了判定

$\left| \frac{\partial f}{\partial x}(x_t, y_t) \right| + \left| \frac{\partial f}{\partial y}(x_t, y_t) \right| < \varepsilon$ ならば終了 そうでなければ, 3に戻る

最急降下法（ニューラルネットの場合）

1. 閾値 $\varepsilon > 0$, ステップ幅 $\alpha > 0$ を設定する
2. $w_{ji}^{(1)}, w_{kj}^{(2)}, i = 0, 1, \dots, D, j = 0, 1, \dots, M, k = 1, \dots, K$ の初期値を設定する
3. $\frac{\partial E_b}{\partial w_{ji}^{(1)}}(w_{10}^{(1)}{}_t, \dots, w_{D1}^{(1)}{}_t, \dots, w_{DM}^{(1)}{}_t, \dots, w_{10}^{(2)}{}_t, \dots, w_{MK}^{(2)}{}_t)$ $i = 0, 1, \dots, D, j = 0, 1, \dots, M$

$$\frac{\partial E_b}{\partial w_{kj}^{(2)}}(w_{10}^{(1)}{}_t, \dots, w_{D1}^{(1)}{}_t, \dots, w_{DM}^{(1)}{}_t, \dots, w_{10}^{(2)}{}_t, \dots, w_{MK}^{(2)}{}_t) \quad j = 0, 1, \dots, M, k = 1, \dots, K$$

の値を計算する

4. $w_{ji}^{(1)}, w_{kj}^{(2)}, i = 0, 1, \dots, D, j = 0, 1, \dots, M, k = 1, \dots, K$ の値を更新する
- $$w_{ji}^{(1)}{}_{t+1} = w_{ji}^{(1)}{}_t - \alpha \frac{\partial E_b}{\partial w_{ji}^{(1)}}(w_{10}^{(1)}{}_t, \dots, w_{D1}^{(1)}{}_t, \dots, w_{DM}^{(1)}{}_t, \dots, w_{10}^{(2)}{}_t, \dots, w_{MK}^{(2)}{}_t)$$
- $$w_{kj}^{(2)}{}_{t+1} = w_{kj}^{(2)}{}_t - \alpha \frac{\partial E_b}{\partial w_{kj}^{(2)}}(w_{10}^{(1)}{}_t, \dots, w_{D1}^{(1)}{}_t, \dots, w_{DM}^{(1)}{}_t, \dots, w_{10}^{(2)}{}_t, \dots, w_{MK}^{(2)}{}_t)$$

5. 終了判定

中間層と出力層の間の重み $w_{kj}^{(2)}$ の更新 (1)

変数の数が多いので、括弧内を省略し、次の様に表記する

$$\frac{\partial E_b}{\partial w_{ji}^{(1)}} : \frac{\partial E_b}{\partial w_{ji}^{(1)}} (w_{10}^{(1)} t, \dots, w_{D1}^{(1)} t, \dots, w_{DM}^{(1)} t, \dots, w_{01}^{(2)} t, \dots, w_{MK}^{(2)} t)$$

$$\vdots$$

$$\frac{\partial E_b}{\partial w_{kj}^{(2)}} : \frac{\partial E_b}{\partial w_{kj}^{(2)}} (w_{10}^{(1)} t, \dots, w_{D1}^{(1)} t, \dots, w_{DM}^{(1)} t, \dots, w_{01}^{(2)} t, \dots, w_{MK}^{(2)} t)$$

中間層と出力層の間の重みを更新するには、 $\frac{\partial E_b}{\partial w_{kj}^{(2)}}$ を計算する必要がある。

チェーンルールにより

$$\frac{\partial E_b}{\partial w_{kj}^{(2)}} = \sum_{n=1}^{N_b} \frac{\partial E_n}{\partial a_{nk}} \times \frac{\partial a_{nk}}{\partial w_{kj}^{(2)}}$$

$$= \sum_{n=1}^{N_b} \delta_{nk} \times \frac{\partial a_{nk}}{\partial w_{kj}^{(2)}}$$

記法 δ の導入

$$\delta_{nk} = \frac{\partial E_n}{\partial a_{nk}}$$

中間層と出力層の間の重み $w_{kj}^{(2)}$ の更新 (2)

$$E_n = \frac{1}{2} \sum_{k=1}^K (y_{nk} - t_{nk})^2$$

教師変数が連続値の場合は、出力層では、変換を行わないので、 $a_{nk} = y_{nk}$ したがって δ_{nk} は誤差(残差)となる。

$$\delta_{nk} = \frac{\partial E_n}{\partial a_{nk}} = y_{nk} - t_{nk}$$

$$a_{nk} = \sum_{j=1}^M w_{kj}^{(2)} z_{nj} + w_{k0}^{(2)}$$


より

$$\frac{\partial a_{nk}}{\partial w_{kj}^{(2)}} = z_{nj}$$

$$\frac{\partial E_n}{\partial w_{kj}^{(2)}} = \frac{\partial E_n}{\partial a_{nk}} \times \frac{\partial a_{nk}}{\partial w_{kj}^{(2)}} = (y_{nk} - t_{nk}) z_{nj} = \delta_{nk} z_{nj}$$

チェーンルール

中間層と出力層の間の重み $w_{kj}^{(2)}$ のバッチ更新



重みの先の δ_k と重みの元の z_j をかけると $\frac{\partial E_n}{\partial w_{kj}^{(2)}}$ が求まる

1. 偏微分の計算

$$\frac{\partial E_b}{\partial w_{kj}^{(2)}} = \sum_{n=1}^{N_b} \frac{\partial E_n}{\partial w_{kj}^{(2)}} = \sum_{n=1}^{N_b} \delta_{nk} z_{nj}$$

2. 重みの更新

$$w_{kj}^{(2)}{}_{t+1} = w_{kj}^{(2)}{}_t - \alpha \frac{\partial E_b}{\partial w_{kj}^{(2)}}$$

$$\begin{aligned} \delta_{nk} &= y_{nk} - t_{nk} \\ j &= 1, 2, \dots, M \\ k &= 1, 2, \dots, K \end{aligned}$$

入力層と中間層の間の重み $w_{ji}^{(1)}$ の更新 (1)

入力層と中間層の間の重みを更新するには、 $\frac{\partial E_n}{\partial w_{ji}^{(1)}}$ を計算する必要がある。

チェーンルールにより

$$\frac{\partial E_n}{\partial w_{ji}^{(1)}} = \frac{\partial E_n}{\partial a_{nj}} \times \frac{\partial a_{nj}}{\partial w_{ji}^{(1)}}$$

$$\begin{aligned} a_{nj} &= \sum_{i=1}^D w_{ji}^{(1)} x_{ni} + w_{j0}^{(1)} \\ \frac{\partial a_{nj}}{\partial w_{ji}^{(1)}} &= x_{ni} \end{aligned}$$

記法 δ の導入

$$\delta_{nj} = \frac{\partial E_n}{\partial a_{nj}}$$

入力層と中間層の間の重み $w_{ji}^{(1)}$ の更新 (2)

チェーンルールにより

$$\delta_{nj} = \frac{\partial E_n}{\partial a_{nj}} = \sum_{k=1}^K \frac{\partial E_n}{\partial a_{nk}} \frac{\partial a_{nk}}{\partial a_{nj}} = \sum_{k=1}^K \delta_{nk} \frac{\partial a_{nk}}{\partial a_{nj}}$$

まとめると

$$\delta_{nj} = (1 - a_{nj})a_{nj} \sum_{k=1}^K \delta_{nk} w_{kj}^{(2)}$$

$$a_{nk} = \sum_{j=1}^M w_{kj}^{(2)} \sigma(a_{nj}) + w_{k0}^{(2)} \text{ より } \frac{\partial a_{nk}}{\partial a_{nj}} = w_{kj}^{(2)} \sigma'(a_{nj}) = w_{kj}^{(2)} (1 - a_{nj})a_{nj}$$

復習：シグモイド関数の性質
 $\sigma'(a_j) = (1 - a_j)a_j$

入力層と中間層の間の重み $w_{ji}^{(1)}$ の更新 (3)


$\delta_{nk} = \frac{\partial E_n}{\partial a_{nk}}$ は既に $w_{kj}^{(2)}$ の更新の際に計算済みなので

$$\delta_{nj} = \frac{\partial E_n}{\partial a_{nj}} = (1 - a_{nj})a_{nj} \sum_{k=1}^K \delta_{nk} w_{kj}^{(2)}$$

$$\frac{\partial E_n}{\partial w_{ji}^{(1)}} = \frac{\partial E_n}{\partial a_{nj}} \frac{\partial a_{nj}}{\partial w_{ji}^{(1)}} = \delta_{nj} x_{ni}$$

$$a_{nj} = \sum_{i=1}^D w_{ji}^{(1)} x_{ni} + w_{j0}^{(1)} \text{ より } \frac{\partial a_{nj}}{\partial w_{ji}^{(1)}} = x_{ni}$$

入力層と中間層の間の重み $w_{ji}^{(1)}$ のバッチ更新



1. 出力層の δ_k から中間層の

$$\delta_{nj} = (1 - a_{nj})a_{nj} \sum_{k=1}^K \delta_{nk} w_{kj}^{(2)}$$

を計算する（誤差逆伝播）。

2.


$$\frac{\partial E_b}{\partial w_{kj}^{(1)}} = \sum_{n=1}^{N_b} \frac{\partial E_n}{\partial w_{kj}^{(1)}} = \sum_{n=1}^{N_b} \delta_{nj} x_{ni}$$

3. 重みの更新

$$w_{ji}^{(1)}{}_{t+1} = w_{ji}^{(1)}{}_t - \alpha \frac{\partial E_n}{\partial w_{ji}^{(1)}} \\ j = 1, 2, \dots, M \\ i = 1, 2, \dots, D$$

まとめ（1）

- 入力変数と教師変数の間の関係をモデルに学習させる
- 層の数、各層の素子数を設定する必要がある
- 入力層、中間層（隠れ層）、出力層の3層構造が良く利用される
- 各層の素子は、結合重み（モデルのパラメータ）でつながっている。
- データが中間層の素子を通過するとき、シグモイド関数で変換される
- 出力層の素子では、学習させるデータのタイプによって、Softmax関数で変換される場合や変換されず、そのまま出力されることもある
- 結合重みは、出力変数と目標値の差が小さくなる様に、学習される→誤差逆伝搬法



まとめ (2)

- 誤差逆伝播法はニューラルネットワークの評価関数に対して最急降下法により、最適化を行っていることに相当する。
- 教師変数が連続値か離散値（カテゴリ変数）かによって、評価関数が異なる。
- n 個のサンプルがある時に、1つ1つのサンプル毎に順伝搬・逆伝搬（重みの更新）を行う方法をオンライン学習と呼び、 n 個のサンプルに対して、一度、順伝搬計算が終わった後、逆伝搬計算を行う方法をバッチ学習と呼ぶ。