




2026年度 前期 データマイニング特論 (I20教室)
第1回 2026年4月16日(木) 13:10~14:40



データマイニング特論

第1回

ガイダンス、イントロダクション+PYTHON環境構築

1

本科目について

本科目の方針などを理解しましょう



本科目シラバスの確認！（基本情報）

【科目名】	データマイニング特論
【単位数】	2.0単位
【担当者】	田中 啓介
【学期】	2025年度前期
【年次】	1年（院）
【授業コード】	21G05061
【曜日・時限】	木曜3限
【ナンバリング】	
【科目コード】	21G05
【ツール】	WebClassを利用する。
【出席管理の方法】	J-port
【授業時の質問方法】	口頭で直接質問する。
【教員Email】	k3tanaka23@rsch.tuis.ac.jp
【授業時間外の質問方法】	オフィスアワー等を利用して直接質問に来るか、メールで問い合わせる。 ⇒ 8号館3階（8304室）



データマイニング特論
LINEグループ もつくりました。
情報共有などの場として活用
してください。

本科目シラバスの確認 2（授業の方針）

【授業概要】 データマイニングは、大規模なデータから有用なパターンや知識を自動的に発見する技術であり、インターネットやIoTの利用拡大に伴い、その重要性はますます高まっている。本科目では、データマイニングおよび機械学習の基本的な手法を、講義とPythonによる実装演習を交えて体系的に学ぶ。具体的には、探索的データ分析、分類（決定木・アンサンブル学習）、クラスタリング、テキストマイニング、異常検知などの手法を段階的に習得し、多分野の実データへの適用を通じて、自身の研究データに応用できる実践力を養う。プログラミングの事前知識は問わない。

【到達目標】

1. Pythonを用いてデータの読み込み、前処理、探索的データ分析を一連の流れとして実行できる。（専門知識・技能）
2. 分類・回帰・クラスタリング等の主要な機械学習手法の原理を説明し、適切な場面で使い分けることができる。（専門知識・技能）
3. モデルの評価指標（精度、再現率、AUC等）を理解し、目的に応じた指標を選択してモデルの性能を適切に評価できる。（専門知識・技能）
4. 自身の研究データに対してデータマイニング手法を適用し、得られた結果を解釈・報告できる。（研究の素養）

【アクティブ・ラーニング型授業】 ディスカッション（討議）／プレゼンテーション（発表）／実習／その他

【授業の方法】 演習を交えながら講義形式で実施する。

出席確認：J-port

講義資料：WebClass

レポート：WebClass

【Point】 J-portとWebClassを必ず確認すること！

本科目シラバスの確認 3（授業計画）

#	日程	内容
第1回	4/16（木）	ガイダンス、イントロダクション+Python環境構築
第2回	4/23（木）	pandasによるデータ操作の基礎
第3回	4/30（木）	探索的データ分析（EDA）と可視化（オンデマンド）
第4回	5/7（木）	データの前処理と特徴量エンジニアリング
第5回	5/14（木）	分類の基礎 — k近傍法と決定木
第6回	5/21（木）	アンサンブル学習
第7回	5/28（木）	線形分類モデルと回帰
第8回	6/4（木）	モデル評価・選択と不均衡データ
第9回	6/11（木）	クラスタリング手法
第10回	6/18（木）	アソシエーション分析と異常検知
第11回	6/25（木）	テキストマイニング
第12回	7/2（木）	時系列データマイニング
第13回	7/9（木）	深層学習の概観と使いどころ
第14回	7/16（木）	公平性・倫理と再現性
第15回	7/23（木）	まとめ

【Point】 やむなく欠席した場合、資料を確認のうえ不明ところは聞いてください。

本科目シラバスの確認 4（評価）

【準備学習・時間外学習】

レポート課題、発表資料の作成、予習、復習を含めて、毎週4時間以上時間外の学習が必要。

【成績評価の方法・評価基準】

・課題（100%）

演習課題の提出もしくはプレゼンテーションによる内容が評価される。

本科目シラバスの確認5（そのほか）

【テキスト】

特になし

【参考書】

適宜、文献や書籍等を提示する。

【キーワード】

データマイニング, 機械学習, 探索的データ分析, 分類, 回帰, クラスタリング, アンサンブル学習, テキストマイニング, 異常検知, 次元削減, 深層学習, モデル評価, 特徴量エンジニアリング, Python

ここまでで何か質問はありますか？

【Point】 シラバスは、よく読んでおいてください。

2

イントロダクション + Python環境構築

はじめに



The background is a dark blue gradient with a subtle pattern of white dots. Overlaid on the left side are several concentric circular patterns. A prominent circular scale with degree markings from 140 to 260 is visible. Other circles of varying sizes and line styles (solid, dashed) are scattered across the left half of the image. The title text is centered horizontally and has a soft orange glow.

イントロダクション

イントロダクション①

- ・「データマイニング」とは？
大規模なデータから、有用なパターンや知識を自動的に発見する技術
- ・ ECサイト
⇒ 購買履歴から「この商品を買った人はこれも買っています」を発見
(Amazon, 楽天市場など)
- ・ メールフィルター
⇒ メールの特徴から迷惑メールかどうかを自動分類
- ・ ゲノミクス
⇒ 数千の遺伝子発現データから疾患関連パターンを検出
- ・ 環境DNA
⇒ メタバーコーディングデータから生物群集の構造を発見

イントロダクション②

- ・KDDプロセス：データから知識へ

KDD (Knowledge Discovery in Databases) とは、
データから意味のある知識を発見する一連の流れのこと。

- ①データ収集
- ②前処理・変換
- ③マイニング（モデル構築）
- ④評価・解釈
- ⑤知識の活用

⇒CRISP-DM (Cross-Industry Standard Process for Data Mining) も同様の循環プロセス。

CRISP-DM：産業界で最も広く使われているフレームワークで、
ビジネス理解→データ理解→準備→モデリング→評価→展開の6フェーズからなる。

本科目では、主に「前処理」から「評価・解釈」までの実践的なスキルを身につける

イントロダクション③

・データマイニングの3本柱

・教師あり学習

⇒「正解付き」データから学ぶ。未知のデータに対して予測する。

分類：スパム判定、疾患予測

回帰：売上予測、発現量予測

・教師なし学習

⇒「正解なし」で構造を発見する。データの中の隠れたパターンを見つける。

クラスタリング：顧客分類、群集構造

異常検知：不正検出、外れ値発見

・発展的手法

⇒特殊なデータ型やより高度な技術に取り組む。

テキストマイニング、時系列分析、深層学習（CNN, RNN）の概観

イントロダクション④

- データマイニング特論との違い

データマイニング特論：

問い：What / How — 何が起きる？どう予測する？

手法：決定木、アンサンブル、クラスタリング、テキストマイニング、深層学習

評価軸：予測精度（AUC、F1、RMSE）

言語：Python

データ解析特論：

問い：Why — なぜそうなるか？効果はどれくらいか？

手法：GLM、混合効果モデル、GAM、ベイズモデリング、生存時間解析

評価軸：モデルの適合度（AIC、尤度比、事後分布）

言語：R

⇒両科目を併せて履修すると「予測と発見」「理解と推論」の両輪が揃います

The background is a dark blue gradient with a subtle pattern of small white dots. Overlaid on this are several faint, light blue circular elements. These include concentric circles of varying sizes, some with dashed lines, and circular arcs with tick marks and degree labels (40, 150, 160, 170, 180, 190, 210, 220, 230, 240, 250, 260). Some of these circles have arrows indicating a clockwise direction.

Python環境構築

Google Colabを使う①

- 「Google Colab」にアクセス
⇒Googleアカウントを持っていない人は、取得してください。

Google Colab interface showing a new notebook titled "Untitled24.ipynb". The interface includes a top menu bar with options like "ファイル", "編集", "表示", "挿入", "ランタイム", "ツール", and "ヘルプ". Below the menu is a toolbar with icons for file operations and a search bar. The main area displays a code cell with the text "コーディングを開始するか、AI で生成します。". On the right side, there is a "リリースノート" (Release Notes) section with two entries: "2026-03-25" and "2026-02-23", detailing updates to Google Colab's features and hardware. The bottom status bar shows "変数" and "ターミナル" tabs.

リリースノート

Please follow our [blog](#) to see more information about new features, tips and tricks, and featured notebooks such as [Analyzing a Bank Failure with Colab](#).

2026-03-25

- Google Colab's marketing site (<http://colab.google>) has a fresh new look!
- Added support for Nvidia RTX Pro 6000 Blackwell Server Edition GPUs on G4 machines. With a peak rating of 960 BF16 TFLOPs (~50% more than the A100-80G) and 96 GB of VRAM (20% more than the A100-80G), it's the most efficient high-performance GPU we've ever offered. Select "G4 GPU" in the runtime type menu.
- Colab's new Open Source MCP Server gives your local agents programmatic access to control the entire notebook development lifecycle. Use your local agent to build, run, and visualize in the browser. ([GitHub Repo](#))
- Python package upgrades
 - accelerate 1.12.0 -> 1.13.0
 - bigframes 2.35.0 -> 2.38.0
 - blosc2 4.0.0 -> 4.1.2
 - diffusers 0.36.0 -> 0.37.0
 - google-adk 1.25.1 -> 1.27.1
 - google-genai 1.64.0 -> 1.67.0
 - h5py 3.15.1 -> 3.16.0
 - huggingface_hub 1.4.1 -> 1.7.1
 - kaggle 1.7.4.5 -> 2.0.0
 - kagglehub 0.3.13 -> 1.0.0
 - keras 3.10.0 -> 3.13.2
 - keras-hub 0.21.1 -> 0.26.0
 - keras-nlp 0.21.1 -> 0.26.0
 - narwhals 2.17.0 -> 2.18.0
 - openai 2.23.0 -> 2.28.0
 - sentence-transformers 5.2.3 -> 5.3.0
 - shap 0.50.0 -> 0.51.0

2026-02-23

- Enterprise Runtimes are now available in Colab - get the familiar notebook you love with the enterprise power you need ([learn more](#)):
 - Persistent runtimes
 - Configurable hardware & powerful GPUs
 - Seamless Vertex AI & BigQuery integration
 - Scale from idea to production without leaving your notebook.
- Launched official PyCharm Colab extension. [Learn more](#).
- Published Colab's CPU Docker runtime image to us-docker.pkg.dev/colab-images/public/cpu-runtime
- Python package upgrades
 - bigframes 2.31.0 -> 2.35.0
 - boto3 3.7.3 -> 3.8.2
 - cudf-cu12 25.10.0 -> 26.2.1
 - cudf-polars-cu12 25.10.0 -> 26.2.1
 - cuml-cu12 25.10.0 -> 26.2.0
 - cupy-cuda12x 13.6.0 -> 14.0.1
 - dask 2025.9.1 -> 2026.1.2
 - dask-cuda 25.10.0 -> 26.2.0
 - dask-cudf-cu12 25.10.0 -> 26.2.1
 - fastapi: 0.123.10 -> 0.133.0
 - google-adk 1.21.0 -> 1.25.1
 - google-auth 2.43.0 -> 2.47.0
 - google-genai 1.55.0 -> 1.64.0
 - holidays 0.88 -> 0.91
 - holidays: 0.88 -> 0.91
 - huggingface-hub: 0.36.0 -> 1.4.1
 - mcp 1.25.0 -> 1.26.0

Google Colabを使う②

・変数とリスト

変数と基本のデータ型

値に名前をつけて保存する。

Python は型を自動で判別してくれる。

```
x = 10          # 整数
pi = 3.14       # 小数
name = "Data Mining" # 文字列
is_fun = True   # 真偽値

print(x, name)
print(type(x))  # <class 'int'>
```

リスト (list)

複数の値をまとめて管理する。

データ分析では最も基本的な構造。

```
scores = [85, 92, 78, 96, 88]

print(scores[0])      # 85 (先頭)
print(scores[1:3])    # [92, 78]
print(len(scores))    # 5

print(sum(scores))    # 合計
print(max(scores))    # 最大
```

Google Colabを使う③

・繰り返しと辞書

forループ

リストの各要素に対して同じ処理を繰り返す。

```
scores = [85, 92, 78, 96, 88]
```

```
# 各スコアを1.1倍にする
```

```
for s in scores:  
    print(s * 1.1)
```

```
# 平均を手計算
```

```
total = 0  
for s in scores:  
    total = total + s  
print(total / len(scores))
```

辞書 (dict)

「名前：値」のペアでデータを管理

```
student = {  
    "name": "Tanaka",  
    "score": 92,  
    "grade": "A"  
}
```

```
print(student["name"])  
print(student["score"])
```


Google Colabを使う④

・グラフを描く

ヒストグラム
分布を見る

```
import matplotlib.pyplot as plt
```

```
scores = [85, 92, 78, 96, 88,  
          73, 91, 82, 95, 79]
```

```
plt.hist(scores, bins=5,  
         color="steelblue",  
         edgecolor="white")  
plt.xlabel("Score")  
plt.ylabel("Count")  
plt.title("Score Distribution")  
plt.show()
```

散布図
関係を見る

```
hours = [2, 3, 1, 5, 4,  
         2, 4, 3, 5, 1]
```

```
plt.scatter(hours, scores,  
            color="coral",  
            edgecolor="gray")  
plt.xlabel("Study Hours")  
plt.ylabel("Score")  
plt.title("Hours vs Score")  
plt.show()
```

この「関係」を自動的に見つけるのが
データマイニング！

3

本日の課題

頑張ってください。



課題

【課題】 期限：2026/4/16（水） 23：59まで

WebClassの『データマイニング特論』アクセスし、
本日の日付が記載される「課題」を期限内に実施してください。

・ WebClass -> データマイニング特論 -> 【第1回（4/16）】課題

（課題1） 本日の演習で実施した「ヒストグラム」と「散布図」の画像ファイルを出力し、
これらを合わせて提出しなさい。